

# Proyecto Final: Ingeniería de Datos en Python

---

Luis Tun

15 de abril de 2024

Se importan las librerías necesarias

# Creación de la Base de Datos en AWS.

```
import boto3
import pandas as pd
import numpy as np
import psycopg2
import configparser
import sql_queries
import binascii
from faker import Faker
import random
import os
```

Se lee el archivo de configuración. Este archivo no se incluye en el repositorio

# Creación de la Base de Datos en AWS.

```
config = configparser.ConfigParser()
```

Nos identificamos con AWS.

# Creación de la base de Datos en AWS.

```
aws_rds_connection = boto3.client('rds',  
aws_access_key_id=config.get('IAM', 'ACCESS_KEY'),  
                               'SECRET_ACCESS_KEY'),  
                               region_name='us-east-2')
```

Se verifica instancias de AWS disponibles en el usuario.



# Creación de la base de Datos en AWS.

```
rds_instances_ids = []

aws_response = aws_rds_connection.describe_db_instances()

for response in aws_response['DBInstances']:
    rds_instances_ids.append(response['DBInstanceIdentifier'])

print(f"Instancias Disponibles: {rds_instances_ids}")
```

Se crea una instancia de Base de Datos en AWS con PostGres.

# Creación de la base de Datos en AWS.

```
try:
```

```
    response = aws_rds_connection.create_db_instance(  
        DBInstanceIdentifier=config.get('TRANSACC', 'DB_INSTANCE_ID'),  
        DBName=config.get('TRANSACC', 'DB_NAME'),  
        DBInstanceClass='db.t3.micro',  
        Engine='postgres',  
        MasterUsername=config.get('TRANSACC', 'DB_USER'),  
        MasterUserPassword=config.get('TRANSACC', 'DB_PASSWORD'),  
        Port=int(config.get('TRANSACC', 'DB_PORT')),  
        PubliclyAccessible=True,  
        VpcSecurityGroupIds=[config.get('VPC', 'SECURITY_GROUP')],  
        AllocatedStorage=15  
    )
```

```
    print(response)
```

```
except aws_rds_connection.exceptions.DBInstanceAlreadyExists  
Fault as ex:
```

```
    print("La instancia ya existe")
```

```
except Exception as ex:
```

```
    print("Error!", ex)
```

Se obtiene el hostname de la instancia.

# Creación de la base de Datos en AWS.

```
try:
    instance = aws_rds_connection.describe_db_instances(DBInstanceIdentifier=config.get('TRANSACC',
        'DB_INSTANCE_ID'))
    RDS_HOSTNAME = instance.get('DBInstances')[0].get('Endpoint').get('Address')
    print(RDS_HOSTNAME)
except Exception as ex:
    print("Error!!", ex)
```

Se hace la conexión a la Base de Datos.

# Creación de la base de Datos en AWS.

```
try:
    db_pg_conn = psycopg2.connect(
        database=config.get('TRANSACC', 'DB_NAME'),
        user=config.get('TRANSACC', 'DB_USER'),
        password=config.get('TRANSACC', 'DB_PASSWORD'),
        host=RDS_HOSTNAME,
        port=int(config.get('TRANSACC', 'DB_PORT'))
    )
    cursor = db_pg_conn.cursor()
    cursor.execute(sql_queries.DDL_QUERY)
    db_pg_conn.commit()
    print("Base de Datos Creada Exitosamente")
except Exception as ex:
    print("Error!", ex)
```

Se crean funciones para inserción de datos.



# Creación de la Base de Datos.

```
def insertData2SQL(data_dict, table_name, driver):  
  
    df_data = pd.DataFrame.from_records(data_dict)  
    try:  
        response = df_data.to_sql(table_name, driver, index=False,  
                                  if_exists='append')  
        print(f"Se han insertado {response} nuevos registros")  
    except Exception as ex:  
        print(ex)
```

# Creación de la Base de Datos.

```
def insertData2SQL_categoria(data_dict, table_name, driver):
    df_data = pd.DataFrame.from_records(data_dict)
    try:
        for index, row in df_data.iterrows():
            estado_value = "'1'" if row.to_dict()['estado'] else "'0'"
            query = f"INSERT INTO {table_name} VALUES\n({row.to_dict()['idcategoria']}, '{row.to_dict()}\n['nombre']}', '{row.to_dict()['descripcion']}',\nCAST({estado_value} AS BIT))"\n            cursor.execute(query)
        db_pg_conn.commit()
        print(f"Se han insertado {len(df_data)} nuevos registros")
    except Exception as ex:
        print(ex)
```

# Creación de la Base de Datos.

```
def insertData2SQL_rol(data_dict, table_name, driver):
    df_data = pd.DataFrame.from_records(data_dict)
    try:
        for index, row in df_data.iterrows():
            estado_value = "'1'" if row.to_dict()['estado'] else "'0'"
            query = f"INSERT INTO {table_name} VALUES\n({row.to_dict()['idrol']}, '{row.to_dict()}\n['nombre']}', '{row.to_dict()['descripcion']}',\nCAST({estado_value} AS BIT))"\n            cursor.execute(query)
        db_pg_conn.commit()
        print(f"Se han insertado {len(df_data)} nuevos registros e
    except Exception as ex:
        print(ex)
```

# Creación de la Base de Datos.

```
def insertData2SQL_articulo(data_dict, table_name, driver):
    df_data = pd.DataFrame.from_records(data_dict)
    try:
        for index, row in df_data.iterrows():
            estado_value = "'1'" if row.to_dict()['estado'] else
                "'0'"
            query = f"INSERT INTO {table_name} VALUES
                ({row.to_dict()['idarticulo']}, '{row.to_dict()
                ['idcategoria']}', '{row.to_dict()['codigo']}',
                '{row.to_dict()['nombre']}', '{row.to_dict()
                ['precio_venta']}', '{row.to_dict()['stock']}',
                '{row.to_dict()['descripcion']}', '{row.to_dict()
                ['imagen']}', CAST({estado_value} AS BIT))"
            cursor.execute(query)
        db_pg_conn.commit()
        print(f"Se han insertado {len(df_data)} nuevos registros
            en la tabla {table_name}")
    except Exception as ex:
        print(ex)
```

# Creación de la Base de Datos.

```
def insertData2SQL_usuario(data_dict, table_name, driver):
    try:
        for row in data_dict:
            estado_value = 1 if row['estado'] else 0
            query = f"INSERT INTO {table_name} VALUES (%s, %s, %s, %s, %s, %s, %s, %s, CAST(%s AS BIT))"
            cursor.execute(query, (
                row['idusuario'],
                row['idrol'],
                row['nombre'],
                row['tipo_documento'],
                row['num_documento'],
                row['direccion'],
                row['telefono'],
                row['email'],
                binascii.hexlify(row['clave']).decode('utf-8'),
                estado_value
            ))
            db_pg_conn.commit()
            print(f"Se han insertado {len(data_dict)} nuevos registros en la tabla {table_name}")
    except Exception as ex:
```

Esta función genera números aleatorios únicos para usar en algunas columnas como el número de documento, número de serie de comprobantes, id, etc.

# Creación de la Base de Datos.

```
def generate_unique_random_numbers(start, end, count):  
    unique_numbers = set()  
    while len(unique_numbers) < count:  
        random_number = np.random.randint(start, end)  
        unique_numbers.add(random_number)  
    return list(unique_numbers)
```

Esta función genera números de teléfono aleatorios de determinados dígitos.



```
def generate_phone_number(digits):  
    phone_number = fake.phone_number()[ :digits]  
    return phone_number
```

Se crea variable driver para que lea las credenciales y para usarse en las funciones de inserción de datos.

# Creación de la Base de Datos.

```
driver = f"""postgresql://{config.get('TRANSACC', 'DB_USER')}:  
{config.get('TRANSACC', 'DB_PASSWORD')}@{RDS_HOSTNAME}:  
{config.get('TRANSACC', 'DB_PORT')}/{config.get('TRANSACC',  
'DB_NAME')}"""
```

Se agregan datos a la tabla categoria.

# Creación de la Base de Datos.

```
data_categoria = [  
    {'idcategoria': 39582, 'nombre': 'Ropa y Accesorios',  
     'descripcion': 'Incluye prendas de vestir para hombres,  
mujeres y niños, así como accesorios como bolsos, sombreros,  
bufandas, etc.', 'estado': True},  
    {'idcategoria': 82016, 'nombre': 'Calzado', 'descripcion':  
     'Incluye zapatos formales, tenis, botas, sandalias, para  
hombres, mujeres y niños.', 'estado': True},  
    {'idcategoria': 51470, 'nombre': 'Juguetes y Juegos',  
     'descripcion': 'Una amplia gama de juguetes para niños de  
todas las edades, así como juegos de mesa y artículos  
deportivos.', 'estado': True},  
    {'idcategoria': 75369, 'nombre': 'Electronicos',  
     'descripcion': 'Desde teléfonos móviles, computadoras  
portátiles y tabletas hasta accesorios como auriculares,  
cargadores y fundas.', 'estado': True},  
    {'idcategoria': 20934, 'nombre': 'Mascotas', 'descripcion':  
     'Ofrece productos para el cuidado de mascotas, alimentos,  
juguetes y accesorios para perros, gatos y otras mascotas.',  
     'estado': True},  
]
```

# Creación de la Base de Datos.

```
{'idcategoria': 64218, 'nombre': 'Alimentos y Bebidas',  
'descripcion': 'Desde alimentos enlatados y productos secos  
hasta bebidas como vinos, cervezas artesanales y licores.',  
'estado': True},  
{'idcategoria': 13750, 'nombre': 'Libros y Papeleria',  
'descripcion': 'Ofrece una selección de libros para todas las edad  
{'idcategoria': 40879, 'nombre': 'Belleza y Cuidado Personal',  
'descripcion': 'Incluye productos de cuidado de la piel,  
maquillaje, perfumes, asi como herramientas y accesorios para el  
cuidado del cabello.', 'estado': True},  
{'idcategoria': 97521, 'nombre': 'Joyeria', 'descripcion': 'Desde  
anillos, pulseras y collares hasta relojes y joyeria  
personalizada.', 'estado': True},  
{'idcategoria': 32684, 'nombre': 'Hogar y Decoracion',  
'descripcion': 'Ofrece muebles para el hogar, articulos de  
decoracion como cuadros y jarrones, asi como utensilios de cocina  
]
```

```
insertData2SQL_categoria(data_categoria, 'categoria', driver)
```

Se agregan datos a la tabla rol.

# Creación de la Base de Datos.

```
data_rols = [  
    {'idrol': 10001, 'nombre': 'Administrador', 'descripcion':  
    'Este rol tiene acceso completo al sistema y puede realizar  
    todas las acciones.', 'estado': True},  
    {'idrol': 10002, 'nombre': 'Moderador', 'descripcion': 'Este  
    rol tiene permisos para moderar contenido y realizar acciones  
    específicas.', 'estado': True},  
    {'idrol': 10003, 'nombre': 'Usuario Estándar', 'descripcion':  
    'Este rol tiene acceso limitado y puede realizar acciones  
    básicas en el sistema.', 'estado': True},  
    {'idrol': 10004, 'nombre': 'Soporte Técnico', 'descripcion':  
    'Este rol proporciona soporte técnico y tiene acceso a  
    herramientas de diagnóstico.', 'estado': True},  
    {'idrol': 10005, 'nombre': 'Invitado', 'descripcion': 'Este  
    rol tiene acceso limitado y solo puede ver contenido  
    público.', 'estado': True}  
]  
  
insertData2SQL_rol(data_rols, 'rol', driver)
```



Se agregan datos a la tabla articulo.

# Creación de la Base de Datos.

```
fake = Faker()

categorias_por_palabra_clave = {
    "camisa": 39582,
    "pantalón": 39582,
    "zapatos": 82016,
    "tenis": 82016,
    "vestido": 39582,
    "reloj": 97521,
    "teléfono": 75369,
    "portátil": 75369,
    "tableta": 75369,
    "juguete": 51470,
    "libro": 13750,
    "silla": 32684,
    "mesa": 32684,
```

# Creación de la Base de Datos.

```
"lámpara": 32684,  
"cuadro": 32684,  
"cocina": 32684,  
"cama": 32684,  
"alfombra": 32684,  
"jarrón": 32684,  
"perfume": 40879,  
"maquillaje": 40879,  
"galleta": 64218,  
"pelota": 51470,  
"anillo": 97521,  
"suéter": 39582,  
"bolígrafo": 13750  
}
```

# Creación de la Base de Datos.

```
palabras_clave = categorias_por_palabra_clave.keys()

articulos_categoria = {}

while len(articulos_categoria) < 1000:
    palabra_clave = random.choice(list(palabras_clave))
    palabra_aleatoria = fake.word().capitalize()
    nombre_articulo = palabra_clave.capitalize() + " " +
    palabra_aleatoria
    id_categoria = categorias_por_palabra_clave[palabra_clave]
    articulos_categoria[nombre_articulo] = id_categoria
```

```
def generar_codigo(length):  
    caracteres = 'abcdefghijklmnopqrstuvwxyzABCDEFGHIJKLMNOPQRSTUVWXYZ  
    QRSTUVWXYZ0123456789'  
    codigo = ''.join(random.choice(caracteres) for _ in  
    range(length))  
    return codigo
```

# Creación de la Base de Datos.

```
cantidad_articulos = 1000
```

```
data_articulos = []
```

```
start_number_articulo = 100000
```

```
end_number_articulo = 999999
```

```
number_count_articulo = cantidad_articulos
```

```
unique_random_numbers_idarticulos = generate_unique_random_numbers  
end_number_articulo, number_count_articulo)
```

```
lista_nombre_articulo = list(articulos_categoria.keys())
```

# Creación de la Base de Datos.

```
for index, articulo in enumerate(range(cantidad_articulos)):
    nombre_articulo = lista_nombre_articulo[index]
    nuevo_articulo = {
        'idarticulo': unique_random_numbers_idarticulos[index],
        'idcategoria': articulos_categoria[nombre_articulo],
        'codigo': generar_codigo(8),
        'nombre': nombre_articulo,
        'precio_venta': round(random.uniform(10, 1000),2),
        'stock': np.random.randint(1, 100),
        'descripcion': f'Artículo {nombre_articulo} en venta en tienda',
        'imagen': 'fig_' + str(index),
        'estado': True
    }
    data_articulos.append(nuevo_articulo)
insertData2SQL_articulo(data_articulos, 'articulo', driver)
```

Se agregan datos a la tabla persona.



# Creación de la Base de Datos.

```
tipo_persona = ['cliente', 'proveedor']
tipo_documento = ['DNI', 'NIE', 'Pasaporte', 'Tarjeta Residencia']

cantidad_personas = 1000

start_number_persona = 100000000
end_number_persona = 999999999
number_count_persona = cantidad_personas

unique_random_numbers_idpersona = generate_unique_random_numbers(s
end_number_persona, number_count_persona)

start_number_num_doc_persona = 1000000000000000
end_number_num_doc_persona = 1999999999999999
number_count_num_doc_persona = cantidad_personas

unique_random_numbers_num_doc_persona = generate_unique_random_num
doc_persona, end_number_num_doc_persona,
number_count_num_doc_persona)
```

# Creación de la Base de Datos.

```
data_personas = []
for index, persona in enumerate(range(cantidad_personas)):
    perfil_persona = fake.profile()
    nombre_persona = perfil_persona['name']
    direccion_persona = perfil_persona['address']
    direccion_persona = direccion_persona.replace("\n", " ")
    email_persona = perfil_persona['mail']
    # Generar un número de teléfono
    numero_telefono = generate_phone_number(8)
    nueva_persona = {
        'idpersona': unique_random_numbers_idpersona[index],
        'tipo_persona': tipo_persona[np.random.randint(0,2)],
        'nombre': nombre_persona,
        'tipo_documento': tipo_documento[np.random.randint(0,4)],
        'num_documento':
            unique_random_numbers_num_doc_persona[index],
        'direccion': direccion_persona,
        'telefono': numero_telefono,
        'email': email_persona,
    }
    data_personas.append(nueva_persona)
insertData2SQL(data_personas, 'persona', driver)
```

Se agregan datos a la tabla usuario.

# Creación de la Base de Datos.

```
cantidad_usuarios = 1000
estados = [True, False]

start_number_usuario = 1000000
end_number_usuario = 9999999
number_count_usuario = cantidad_usuarios

unique_random_numbers_idusuario =
generate_unique_random_numbers(start_number_usuario,
end_number_usuario, number_count_usuario)

start_number_num_doc_usuario = 1000000000000000
end_number_num_doc_usuario = 1999999999999999
number_count_num_doc_usuario = cantidad_usuarios

unique_random_numbers_num_doc_usuario =
generate_unique_random_numbers(start_number_num_doc_usuario,
end_number_num_doc_usuario, number_count_num_doc_usuario)

data_usuarios = []
```

# Creación de la Base de Datos.

```
for index, usuario in enumerate(range(cantidad_usuarios)):
    perfil_persona = fake.profile()
    nombre_persona = perfil_persona['name']
    direccion_persona = perfil_persona['address']
    direccion_persona = direccion_persona.replace("\n", " ")
    email_persona = perfil_persona['mail']
    longitud_bytes = 10
    dato_binario = os.urandom(longitud_bytes)
    numero_telefono = generate_phone_number(8)
    nuevo_usuario = {
        'idusuario': unique_random_numbers_idusuario[index],
        'idrol': random.choices(data_rols, weights=(0.1, 0.2, 0.4),
                                k=1)[0],
        'nombre': nombre_persona,
        'tipo_documento': tipo_documento[np.random.randint(0,3)],
        'num_documento': unique_random_numbers_num_doc_usuario[index],
        'direccion': direccion_persona,
        'telefono': numero_telefono,
        'email': email_persona,
        'clave': dato_binario,
        'estado': estados[np.random.randint(0,2)],
    }
    data_usuarios.append(nuevo_usuario)
```

Se agregan datos a la tabla venta.

# Creación de la Base de Datos.

```
cantidad_venta = 1000
tipos_comprobante = ['Factura', 'Boleta de Venta', 'Ticket de
Venta', 'Nota de Crédito', 'Nota de Débito', 'Recibo']
estados_venta = ['Pendiente', 'En proceso', 'Completada',
'Cancelada', 'Reembolsada']

fecha_inicio = datetime(2015, 1, 1)
fecha_fin = datetime(2023, 12, 31)
fecha_aleatoria = fecha_inicio + timedelta(days=random.randint(0,
(fecha_fin - fecha_inicio).days))
start_number_venta = 111111
end_number_venta = 999999

number_count_venta = cantidad_venta
unique_random_numbers_idventa =

generate_unique_random_numbers(start_number_venta,
end_number_venta, number_count_venta)
start_number_serie_comprob = 1000000
end_number_serie_comprob = 9999999
number_count_serie_comprob = cantidad_venta
```

# Creación de la Base de Datos.

```
unique_random_numbers_serie_comprob = generate_unique_random_numbers  
end_number_serie_comprob, number_count_serie_comprob)
```

```
start_number_num_comprob = 10000000  
end_number_num_comprob = 99999999  
number_count_num_comprob = cantidad_venta
```

```
unique_random_numbers_num_comprob = generate_unique_random_numbers  
end_number_num_comprob, number_count_num_comprob)
```

```
data_venta = []
```



## Paso 6.

```
for index, venta in enumerate(range(cantidad_venta)):
    index_usuario = np.random.randint(0, len(data_usuarios))
    idusuario = data_usuarios[index_usuario]['idusuario']
    fecha_aleatoria = fecha_inicio + timedelta(days=random.randint(
nueva_venta = {
    'idventa': unique_random_numbers_idventa[index],
    'idcliente': random.sample(data_personas, 1)[0]
    ['idpersona'],
    'idusuario': random.sample(data_usuarios, 1)[0]
    ['idusuario'],
    'tipo_comprobante':
tipos_comprobante[np.random.randint(0,6)],
    'serie_comprobante':
unique_random_numbers_serie_comprob[index],
    'num_comprobante':
unique_random_numbers_num_comprob[index],
    'fecha': fecha_aleatoria,
    'impuesto': round(random.uniform(0, 99.99), 2),
    'total': round(random.uniform(0, 99999.99), 2),
    'estado': estados_venta[np.random.randint(0,5)]
}
data_venta.append(nueva_venta)
```

Se agregan datos a la tabla detalles venta.

# Creación de la Base de Datos.

```
cantidad_detalle_venta = 5000

start_number_detalle_venta = 3333333
end_number_detalle_venta = 9999999
number_count_detalle_venta = cantidad_detalle_venta

unique_random_numbers_iddetalle_venta =
generate_unique_random_numbers(start_number_detalle_venta ,
end_number_detalle_venta , number_count_detalle_venta)
```

# Creación de la Base de Datos.

```
data_detalle_venta = []
for index, detalles_venta in
enumerate(range(cantidad_detalle_venta)):
    muestra_tabla_articulo = random.sample(data_articulos, 1)
    idarticulo_muestra = muestra_tabla_articulo[0]['idarticulo']
    precio_muestra = muestra_tabla_articulo[0]['precio_venta']
    nuevo_detalle_venta = {
        'iddetalle_venta':
            unique_random_numbers_iddetalle_venta[index],
        'idventa': random.sample(data_venta, 1)[0]['idventa'],
        'idarticulo': idarticulo_muestra,
        'cantidad': np.random.randint(0,100),
        'precio': precio_muestra,
        'descuento': round(random.uniform(0, 999.99), 2)
    }
    data_detalle_venta.append(nuevo_detalle_venta)
insertData2SQL(data_detalle_venta, 'detalle_venta', driver)
```

Se agregan datos a la tabla ingreso.

# Creación de la Base de Datos.

```
cantidad_ingresos = 1000
estados_ingreso = ['Pendiente', 'En proceso', 'Completada',
'Cancelada', 'Reembolsada']
```

```
start_number_ingreso = 100000000
end_number_ingreso = 999999999
number_count_ingreso = cantidad_ingresos
```

```
unique_random_numbers_idingreso =
generate_unique_random_numbers(start_number_ingreso,
end_number_ingreso, number_count_ingreso)
```

```
start_number_serie_comprob_ingreso = 1000000
end_number_serie_comprob_ingreso = 9999999
number_count_serie_comprob_ingreso = cantidad_ingresos
```

```
unique_random_numbers_serie_comprob_ingreso =
generate_unique_random_numbers(start_number_serie_comprob_ingreso,
end_number_serie_comprob_ingreso,
number_count_serie_comprob_ingreso)
```

# Creación de la Base de Datos.

```
data_ingresos = []
for index, ingreso in enumerate(range(cantidad_ingresos)):
    fecha_aleatoria = fecha_inicio +
    timedelta(days=random.randint(0, (fecha_fin -
    fecha_inicio).days))
    nuevo_ingreso = {
        'idingreso': unique_random_numbers_idingreso[index],
        'idproveedor': random.sample(data_personas, 1)[0]
        ['idpersona'],
        'idusuario': random.sample(data_usuarios, 1)[0]
        ['idusuario'],
        'tipo_comprobante':
        tipos_comprobante[np.random.randint(0,6)],
        'serie_comprobante':
        unique_random_numbers_serie_comprob_ingreso[index],
        'fecha': fecha_aleatoria,
        'impuesto': round(random.uniform(0, 99.99), 2),
        'total': round(random.uniform(0, 99999.99), 2),
        'estado': estados_ingreso[np.random.randint(0,5)]
    }
    data_ingresos.append(nuevo_ingreso)
insertData2SQL(data_ingresos, 'ingreso', driver)
```

Se agregan datos a la tabla detalle ingreso.



# Creación de la Base de Datos.

```
cantidad_detalle_ingreso = 1000

start_number_detalle_ingreso = 100000000
end_number_detalle_ingreso = 999999999
number_count_detalle_ingreso = cantidad_detalle_ingreso

unique_random_numbers_iddetalle_ingreso =
generate_unique_random_numbers(start_number_detalle_ingreso ,
end_number_detalle_ingreso , number_count_detalle_ingreso)
```

# Creación de la Base de Datos.

```
data_detalle_ingreso = []
for index, detalles_ingreso in
enumerate(range(cantidad_detalle_ingreso)):
    muestra_tabla_articulo = random.sample(data_articulos, 1)
    idarticulo_muestra = muestra_tabla_articulo[0]['idarticulo']
    precio_muestra = muestra_tabla_articulo[0]['precio_venta']
    nuevo_detalle_ingreso = {
        'iddetalle_ingreso':
            unique_random_numbers_iddetalle_ingreso[index],
        'idingreso': random.sample(data_ingresos, 1)[0]
            ['idingreso'],
        'idarticulo': idarticulo_muestra,
        'cantidad': np.random.randint(0,100),
        'precio': precio_muestra
    }
    data_detalle_ingreso.append(nuevo_detalle_ingreso)
insertData2SQL(data_detalle_ingreso, 'detalle_ingreso', driver)
```

Se crea la dimensión de la tabla persona.

## Creación de Data Warehouse.

```
sql_query = 'SELECT * FROM persona;'  
dimPersonas = pd.read_sql(sql_query, postgres_driver)  
dimPersonas.to_csv('dimPersonas.csv', index=False)  
dimPersonas.head()
```

Se crea la dimensión de la tabla usuario.

# Creación de Data Warehouse.

```
sql_query = 'SELECT * FROM usuario;'  
df_usuario = pd.read_sql(sql_query, postgres_driver)  
df_usuario = df_usuario.rename(columns={'nombre':  
'nombre_usuario', 'estado': 'estado_usuario'})  
  
sql_query = 'SELECT * FROM rol;'  
df_rol = pd.read_sql(sql_query, postgres_driver)  
df_rol = df_rol.rename(columns={'nombre': 'nombre_rol', 'estado':  
'estado_rol'})
```

```
df_usuario = df_usuario.merge(df_rol, how='inner', on='idrol')  
dimUsuario = df_usuario.drop(['idrol'], axis=1)  
dimUsuario.to_csv('dimUsuario.csv', index=False)
```

Se crea la dimensión de la tabla articulo.



## Creación de Data Warehouse.

```
sql_query = 'SELECT * FROM articulo;'
df_articulo = pd.read_sql(sql_query, postgres_driver)
df_articulo = df_articulo.rename(columns={'nombre':
'nombre_articulo', 'descripcion': 'descripcion_articulo',
'estado': 'estado_articulo'})

sql_query = 'SELECT * FROM categoria;'
df_categoria = pd.read_sql(sql_query, postgres_driver)
df_categoria = df_categoria.rename(columns={'nombre':
'nombre_categoria', 'descripcion': 'descripcion_categoria',
'estado': 'estado_categoria'})
```

## Creación de Data Warehouse.

```
df_articulo = df_articulo.merge(df_categoria, how='inner',  
on='idcategoria')  
dimArticulo = df_articulo.drop(['idcategoria'], axis=1)  
dimArticulo.to_csv('dimArticul.csv', index=False)
```

Se crea la dimensión de la tabla venta.

# Creación de Data Warehouse.

```
sql_query = 'SELECT * FROM venta;'
df_venta = pd.read_sql(sql_query, postgres_driver)
df_venta = df_venta.rename(columns={'estado': 'estado_venta'})

sql_query = 'SELECT * FROM persona'
df_cliente = pd.read_sql(sql_query, postgres_driver)
df_cliente = df_cliente[df_cliente['tipo_persona']=='cliente']
df_cliente = df_cliente.rename(columns={'idpersona': 'idcliente',
'nombre': 'nombre_cliente', 'tipo_documento':
'tipo_documento_cliente', 'num_documento':
'num_documento_cliente', 'direccion': 'direccion_cliente',
'telefono': 'telefono_cliente', 'email': 'email_cliente'})
```

# Creación de Data Warehouse.

```
df_venta_cliente = df_venta.merge(df_cliente, how='inner',  
on='idcliente')  
  
sql_query = 'SELECT * FROM usuario;'  
df_usuario = pd.read_sql(sql_query, postgres_driver)  
df_usuario = df_usuario.rename(columns={'nombre':  
'nombre_usuario', 'tipo_documento': 'tipo_documento_usuario',  
'num_documento': 'num_documento_usuario', 'direccion':  
'direccion_usuario', 'telefono': 'telefono_usuario', 'email':  
'email_usuario', 'estado': 'estado_cliente'})
```

## Creación de Data Warehouse.

```
df_venta_cliente_usuario = df_venta_cliente.merge(df_usuario,  
how='inner', on='idusuario')  
dimVenta = df_venta_cliente_usuario.drop(['idcliente',  
'idusuario', 'idrol'], axis=1)  
dimVenta.to_csv('dimVenta.csv', index=False)
```

Se crea la dimensión de la tabla ingreso.

# Creación de Data Warehouse.

```
sql_query = 'SELECT * FROM ingreso;'  
df_ingreso = pd.read_sql(sql_query, postgres_driver)  
df_ingreso = df_ingreso.rename(columns={'estado':  
'estado_ingreso'})
```

```
sql_query = 'SELECT * FROM persona;'  
df_proveedor = pd.read_sql(sql_query, postgres_driver)  
df_proveedor =  
df_proveedor[df_proveedor['tipo_persona']=='proveedor']  
df_proveedor = df_proveedor.rename(columns={'idpersona':  
'idproveedor', 'nombre': 'nombre_proveedor', 'tipo_documento':  
'tipo_documento_proveedor', 'num_documento':  
'num_documento_proveedor', 'direccion': 'direccion_proveedor',  
'telefono': 'telefono_proveedor', 'email': 'email_proveedor'})
```



## Creación de Data Warehouse.

```
df_ingreso_proveedor = df_ingreso.merge(df_proveedor,
how='inner', on='idproveedor')

sql_query = 'SELECT * FROM usuario'
df_usuario = pd.read_sql(sql_query, postgres_driver)
df_usuario = df_usuario.rename(columns={'nombre':
'nombre_usuario', 'tipo_documento': 'tipo_documento_usuario',
'num_documento': 'num_documento_usuario', 'direccion':
'direccion_usuario', 'telefono': 'telefono_usuario', 'email':
'email_usuario', 'estado': 'estado_usuario'})
```

## Creación de Data Warehouse.

```
dimIngreso = df_ingreso_proveedor.merge(df_usuario, how='inner',  
on='idusuario')  
dimIngreso.drop(['idproveedor', 'idusuario', 'idrol'], axis=1,  
inplace=True)  
dimIngreso.to_csv('dimIngreso.csv', index=False)
```

Se crea la dimensión de la tabla detalle venta.

# Creación de Data Warehouse.

```
sql_query = 'SELECT * FROM detalle_venta;'  
df_detalle_venta = pd.read_sql(sql_query, postgres_driver)  
  
sql_query = 'SELECT * FROM venta;'  
df_venta = pd.read_sql(sql_query, postgres_driver)  
df_venta = df_venta.rename(columns={'estado': 'estado_venta'})
```

## Creación de Data Warehouse.

```
df_detalle_venta_venta = df_detalle_venta.merge(df_venta,  
how='inner', on='idventa')
```

```
sql_query = 'SELECT *FROM articulo;'  
df_articulo = pd.read_sql(sql_query, postgres_driver)  
df_articulo = df_articulo.rename(columns={'estado':  
'estado_articulo'})
```

## Creación de Data Warehouse.

```
dimDetalleVenta = df_detalle_venta_venta.merge(df_articulo,  
how='inner', on='idarticulo')  
dimDetalleVenta.drop(['idventa', 'idarticulo', 'idcliente',  
'idusuario'], axis=1, inplace=True)  
dimDetalleVenta.to_csv('dimDetalleventa.csv', index=False)
```

Se crea la dimensión de la tabla detalle ingreso.

## Creación de Data Warehouse.

```
sql_query = 'SELECT * FROM detalle_ingreso;'  
df_detalle_ingreso = pd.read_sql(sql_query, postgres_driver)  
  
sql_query = 'SELECT * FROM ingreso;'  
df_ingreso = pd.read_sql(sql_query, postgres_driver)  
df_ingreso = df_ingreso.rename(columns={'estado':  
    'estado_ingreso'})
```



## Creación de Data Warehouse.

```
df_detalle_ingreso_ingreso =  
df_detalle_ingreso.merge(df_ingreso, how='inner', on='idingreso')  
  
sql_query = 'SELECT * FROM articulo;'  
df_articulo = pd.read_sql(sql_query, postgres_driver)  
df_articulo = df_articulo.rename(columns={'estado':  
'estado_articulo', 'nombre': 'nombre_articulo'})
```

## Creación de Data Warehouse.

```
dimDetalleIngreso = df_detalle_ingreso_ingreso.merge(df_articulo,  
on='idarticulo')  
dimDetalleIngreso.drop(['idingreso', 'idarticulo',  
'idproveedor', 'idusuario'], axis=1, inplace=True)  
dimDetalleIngreso.to_csv('dimDetalleIngreso.csv', index=False)
```

Se crea la dimensión de la tabla rol.

# Creación de Data Warehouse.

```
sql_query = 'SELECT * FROM rol;'  
dimRol = pd.read_sql(sql_query, postgres_driver)  
dimRol.to_csv('dimRol.csv', index=False)
```

Se crea la dimensión de la tabla categoria.

```
sql_query = 'SELECT * FROM categoria;'  
dimCategoria = pd.read_sql(sql_query, postgres_driver)  
dimCategoria.to_csv('dimCategoria.csv', index=False)
```

Se crea la dimensión de la tabla de tiempo.

# Creación de Data Warehouse.

```
sql_query = 'SELECT fecha FROM venta;'
dimFecha = pd.read_sql(sql_query, postgres_driver)

dimFecha['year'] = pd.DatetimeIndex(dimFecha['fecha']).year
dimFecha['month'] = pd.DatetimeIndex(dimFecha['fecha']).month
dimFecha['quarter'] = pd.DatetimeIndex(dimFecha['fecha']).quarter
dimFecha['day'] = pd.DatetimeIndex(dimFecha['fecha']).day
dimFecha['week'] = pd.DatetimeIndex(dimFecha['fecha']).week
dimFecha['dayofweek'] =
pd.DatetimeIndex(dimFecha['fecha']).dayofweek
dimFecha['is_weekend'] = dimFecha['dayofweek'].apply(lambda x: 1
if x > 5 else 0)
```



# Creación de Data Warehouse.

```
dimFecha['id_fecha'] = dimFecha['year'].astype(str) +  
dimFecha['month'].astype(str)  
dimFecha['id_fecha'] = dimFecha['id_fecha'].astype(str) +  
dimFecha['day'].astype(str)  
  
dimFecha.drop_duplicates(inplace=True)  
dimFecha.to_csv('dimFecha.csv', index=False)
```

Se crea la tabla de hechos.

# Creación de Data Warehouse.

```
sql_query = '''SELECT idventa, fecha, idcliente,
                    idusuario, tipo_comprobante, serie_comprobante,
                    num_comprobante, impuesto, total,
                    estado FROM venta;'''
df_factTable = pd.read_sql(sql_query, postgres_driver)
df_factTable.to_csv('Tabla_de_Hechos.csv', index=False)
```

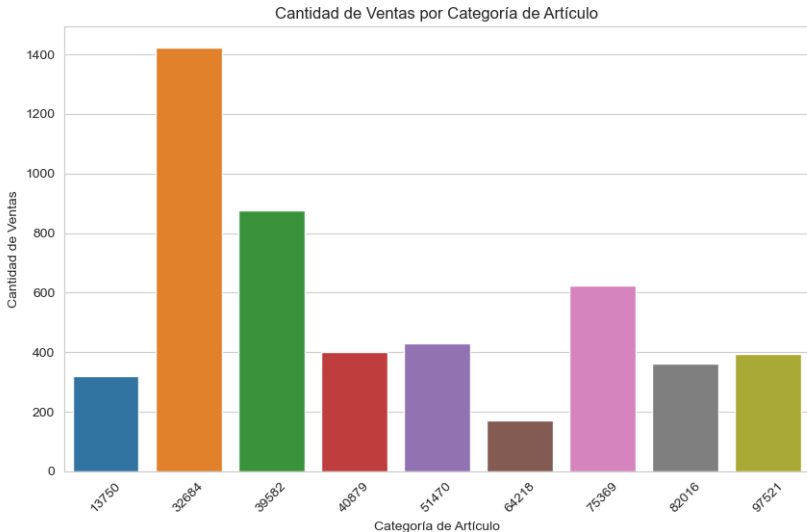
### Pregunta No.1

¿Cuáles son las categorías de artículo más vendidas?

```
data_Detalles_Venta = pd.read_csv('dimDetalleVenta.csv')

plt.figure(figsize=(10, 6))
sns.countplot(data=data_Detalles_Venta, x='idcategoria')
plt.title('Cantidad de Ventas por Categoría de Artículo')
plt.xlabel('Categoría de Artículo')
plt.ylabel('Cantidad de Ventas')
plt.xticks(rotation=45)
plt.show()
```

# Preguntas de Negocio.



Pregunta No.2

¿Cómo varía el total de ventas entre estas categorías?

# Preguntas de Negocio.


```
data_Detalles_Venta['fecha'] =  
pd.to_datetime(data_Detalles_Venta['fecha'])  
  
ventas_mensuales =  
data_Detalles_Venta.groupby(pd.Grouper(key='fecha',  
freq='M')).agg({'total': 'sum'}).reset_index()  
  
ventas_trimestrales =  
data_Detalles_Venta.groupby(pd.Grouper(key='fecha',  
freq='Q')).agg({'total': 'sum'}).reset_index()  
  
ventas_anuales =  
data_Detalles_Venta.groupby(pd.Grouper(key='fecha',  
freq='Y')).agg({'total': 'sum'}).reset_index()
```



# Preguntas de Negocio.

```
sns.set_style("whitegrid")
ticks_seleccionados = ventas_mensuales['fecha'][:3]
plt.figure(figsize=(12, 6))
sns.barplot(x=ventas_mensuales['fecha'].dt.strftime('%b %Y'),
y=ventas_mensuales['total'], color='skyblue')
plt.title('Total de Ventas Mensuales')
plt.xlabel('Fecha')
plt.ylabel('Total de Ventas')
# Establecer los ticks del eje x
plt.xticks(ticks=ticks_seleccionados.index,
labels=ticks_seleccionados.dt.strftime('%b %Y'), rotation=45,
ha='center')
plt.tight_layout()
plt.show()
```


# Preguntas de Negocio.



# Preguntas de Negocio.

```
plt.figure(figsize=(12, 6))
sns.barplot(x=ventas_trimestrales['fecha'].dt.to_period('Q').astype(str), y=ventas_trimestrales['total'], color='lightgreen')
plt.title('Total de Ventas Trimestrales')
plt.xlabel('Fecha')
plt.ylabel('Total de Ventas')
plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()
```


# Preguntas de Negocio.



## Preguntas de Negocio.

```
plt.figure(figsize=(12, 6))
sns.barplot(x=ventas_anuales['fecha'].dt.strftime('%Y'),
            y=ventas_anuales['total'], color='salmon')
plt.title('Total de Ventas Anuales')
plt.xlabel('Fecha')
plt.ylabel('Total de Ventas')
plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()
```

# Preguntas de Negocio.



### Pregunta No.3

¿Qué rol o roles tienden a tener un mayor impacto en el resultado final de las ventas?

## Preguntas de Negocio.

```
sql_query = 'SELECT * FROM venta;'
df_venta = pd.read_sql(sql_query, postgres_driver)
df_venta = df_venta.rename(columns={'estado': 'estado_venta'})
```



## Preguntas de Negocio.

```
sql_query = 'SELECT * FROM persona'
df_cliente = pd.read_sql(sql_query, postgres_driver)
df_cliente = df_cliente[df_cliente['tipo_persona']=='cliente']
df_cliente = df_cliente.rename(columns={'idpersona':
'idcliente', 'nombre': 'nombre_cliente', 'tipo_documento':
'tipo_documento_cliente', 'num_documento':
'num_documento_cliente', 'direccion': 'direccion_cliente',
'telefono': 'telefono_cliente', 'email': 'email_cliente'})
```

## Preguntas de Negocio.

```
df_venta_cliente = df_venta.merge(df_cliente, how='inner',  
on='idcliente')
```

```
sql_query = 'SELECT * FROM usuario;'
df_usuario = pd.read_sql(sql_query, postgres_driver)
df_usuario = df_usuario.rename(columns={'nombre':
'nombre_usuario', 'tipo_documento': 'tipo_documento_usuario',
'num_documento': 'num_documento_usuario', 'direccion':
'direccion_usuario', 'telefono': 'telefono_usuario', 'email':
'email_usuario', 'estado': 'estado_cliente'})
```

## Preguntas de Negocio.

```
df_venta_cliente_usuario = df_venta_cliente.merge(df_usuario,  
how='inner', on='idusuario')  
df_venta_cliente_usuario =  
df_venta_cliente_usuario.drop(['idcliente'], axis=1)
```

## Preguntas de Negocio.

```
data_rols = pd.read_csv('dimRol.csv')


usuarios_rols = pd.merge(df_venta_cliente_usuario, data_rols,
how='left', on='idrol')

ventas_por_rol = usuarios_rols.groupby('idrol')
['total'].sum().reset_index()

plt.figure(figsize=(10, 6))
ax = sns.barplot(x='idrol', y='total',
data=ventas_por_rol.sort_values(by='total', ascending=False))
plt.xlabel('Rol')
plt.ylabel('Total de Ventas ')
plt.title('Total de Ventas por Rol')
plt.xticks(rotation=45)

for index, row in ventas_por_rol.iterrows():
    ax.text(index, row['total'], str(round(row['total'], 2)),
    color='black', ha="center")
plt.show()
```

# Preguntas de Negocio.



### Pregunta No.4


¿Cómo varían las ventas en diferentes momentos del año, como durante las vacaciones o eventos especiales?

# Preguntas de Negocio.

```
ventas_verano =  
data_Detalles_Venta[(data_Detalles_Venta['fecha'].dt.month >= 3)  
& (data_Detalles_Venta['fecha'].dt.month <= 4)]  
  
ventas_verano_mensuales =  
ventas_verano.groupby(pd.Grouper(key='fecha',  
freq='M')).agg({'total': 'sum'}).reset_index()  
  
plt.figure(figsize=(12, 6))  
sns.lineplot(x='fecha', y='total', data=ventas_verano_mensuales)  
plt.title('Ventas Mensuales durante el Verano')  
plt.xlabel('Fecha')  
plt.ylabel('Total de Ventas')  
plt.show()
```



# Preguntas de Negocio.




# Preguntas de Negocio.

```
ventas_fin_de_anio =  
data_Detalles_Venta[(data_Detalles_Venta['fecha'].dt.month >=  
11) & (data_Detalles_Venta['fecha'].dt.month <= 12)]
```

```
ventas_fin_de_anio_mensuales =  
ventas_fin_de_anio.groupby(pd.Grouper(key='fecha',  
freq='M')).agg({'total': 'sum'}).reset_index()
```

```
plt.figure(figsize=(12, 6))  
sns.lineplot(x='fecha', y='total',  
data=ventas_fin_de_anio_mensuales)  
plt.title('Ventas Mensuales durante el Fin de Año')  
plt.xlabel('Fecha')  
plt.ylabel('Total de Ventas')  
plt.show()
```

# Preguntas de Negocio.



### Pregunta No.5

¿Cómo se correlaciona el nivel de stock de los artículos con las ventas realizadas?

¿Existen artículos que constantemente tienen un bajo nivel de stock pero alta demanda?

## Preguntas de Negocio.

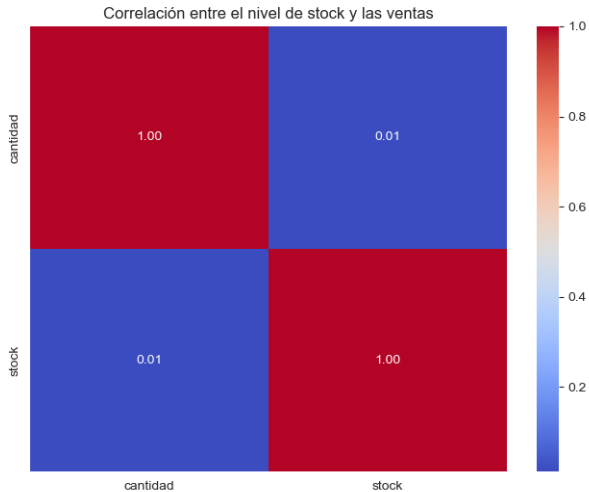
```
correlation = data_Detalles_Venta[['cantidad', 'stock']].corr()

low_stock_items =
data_Detalles_Venta[data_Detalles_Venta['stock'] < 10]

high_demand_items =
data_Detalles_Venta[data_Detalles_Venta['cantidad'] >
data_Detalles_Venta['cantidad'].mean()]

plt.figure(figsize=(8, 6))
sns.heatmap(correlation, annot=True, cmap='coolwarm', fmt=".2f")
plt.title('Correlación entre el nivel de stock y las ventas')
plt.show()
```

# Preguntas de Negocio.



## Preguntas de Negocio.

```
plt.figure(figsize=(10, 6))
sns.scatterplot(data=low_stock_items, x='stock', y='cantidad',
hue='nombre')
plt.title('Artículos con bajo nivel de stock pero alta demanda')
plt.xlabel('Stock')
plt.ylabel('Cantidad Vendida')
plt.legend(title='Artículo', bbox_to_anchor=(1.05, 1), loc='upper
plt.show()
```

# Preguntas de Negocio.

